PUCPR

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ

DATA ANALYTICS / PROJETO BASEADO EM PROBLEMAS

RA1

Ingestão e preparação dos dados

Projeto: Dengue em 2026: Dinâmica de Transmissão, Perfil Populacional e Fatores de Gravidade

Curso: Sistemas de Informação • 6°período • Turma: A GCL1

Professora: Marina de Lara

Equipe

- Bruna da Silva Carnelossi
- João Pedro de Souza Quintiliano da Silva
- João Victor Carvalho de Freitas
- Matheus Henrique Heinzen

Repositório https://github.com/JoaoVictorCarvalho07/api-dados-abertos-saude

Entrega Curitiba • 21/10/2026

RA1 / 01

Problema e perguntas analíticas

Contexto e problema

A dengue permanece um desafio constante para a saúde pública no Brasil, com surtos sazonais agravados por fenômenos climáticos como o El Niño e pelo aumento das temperaturas globais, que impulsionaram recordes históricos com milhões de casos em 2024. Diante desse cenário, esta pesquisa analisa o comportamento da doença no país em 2026, identificando os meses de maior incidência e os estados com maior volume de notificações, além de investigar como fatores demográficos e de saúde (como sexo, faixa etária e presença de comorbidades como diabetes e hipertensão) influenciam a proporção de casos que evoluem com sinais de alarme ou gravidade. Compreender essa dinâmica é fundamental para dimensionar o impacto do problema na população e orientar ações de prevenção e planejamento nos serviços de saúde nos momentos de maior pressão epidemiológica.

Objetivo e recorte

Objetivo: Ingerir, diagnosticar e preparar os dados de notificações de dengue no Brasil em 2026 para analisar a dinâmica temporal, o perfil sociodemográfico dos afetados e a associação de comorbidades e fatores demográficos com o agravamento e evolução dos casos.

Período: Ano epidemiológico de 2026.

População/Unidade de análise: Notificações de suspeita/confirmação de dengue registradas no SINAN/MS em todo o território nacional (Brasil).

Limites do projeto: Análise restrita exclusivamente a casos notificados de dengue (excluindo chikungunya e zika do dataset final) e dependente da qualidade de preenchimento dos campos do SINAN.

Perguntas analíticas

ID	Pergunta a investigar	Dados necessários
P1	Qual mês de 2026 obteve o maior pico de casos de dengue no Brasil e qual foi o estado mais afetado?	DT_SIN_PRI, SEM_PRI, ID_REGIONA, ID_MUNICIP
P2	O índice de gravidade da dengue (sinais de alarme/dengue grave) é maior para homens ou mulheres?	CS_SEXO, CLASSI_FIN
P3	A proporção de casos com sinais de alarme ou dengue grave varia por faixa etária e pela presença de comorbidades (diabetes, hipertensão)?	DT_SIN_PRI, DT_NOTIFIC, SEM_NOT,

Viabilidade inicial

Viabilidade: Os dados do SINAN/DEMAS fornecem abrangência nacional, com informações detalhadas sobre datas de sintomas/notificação, perfil sociodemográfico (sexo, idade) e quadro clínico/comorbidades.

O SINAN coleta e processa as notificações de dengue enviadas por municípios e estados. O DEMAS consome a base de dados tratada (e anonimizada) do SINAN e a envelopa no endpoint de Arboviroses da API de Dados Abertos para que desenvolvedores e pesquisadores possam consumi-la facilmente.

Lacunas e desafios: Necessidade do auxílio de dicionário de dados para compreensão da qualidade dos dados. Presença de campos subpreenchidos ou ignorados (valores nulos ou preenchidos como "9 - Ignorado"), além de possíveis atrasos de notificação nas semanas epidemiológicas mais recentes de 2026.

RA1 / 02

Fontes de dados e ingestão

Ficha da fonte

Identificação: F1 - Notificações de Dengue do Brasil (SINAN - 2026)

Origem e acesso

- **Instituição ou autor:** DEMAS - Departamento de Monitoramento, Avaliação e Disseminação de Informações Estratégicas em Saúde
- **URL:**
  - **Caminho para baixar o CSV:** https://dadosabertos.saude.gov.br/dataset/arboviroses-dengue
  - **Api que disponibiliza os dados:** https://apidadosabertos.saude.gov.br/v1/#/
- **Data de Acesso:** mês de outubro de 2026 (atualizada por ultimo dia 10/out)

Formato e volume

- **Formato:** CSV
- **Registros aproximados:** ~470.000 linhas
- **Atributos:** ~120 colunas (reduzidas na seleção de atributos)

Cobertura: Período de 2026, abrangência nacional (Brasil).

Condições de uso: Dados abertos/públicos (Licença Aberta Governamental - Sem restrições).

Relação com o problema

O Departamento de Monitoramento, Avaliação e Disseminação de Informações Estratégicas em Saúde (DEMAS) é uma unidade integrante da Secretaria da Informação e Saúde Digital (SEIDIGI) do Ministério da Saúde (MS). Ele é responsável por desenvolver o monitoramento e avaliação das ações de saúde e pela construção de uma estrutura especializada em produção, qualificação e disseminação de dados e informações estratégicas para gestores, pesquisadores e cidadãos em prol da melhoria da saúde da sociedade brasileira.

Esta fonte permitirá responder às perguntas P1, P2 e P3 através do cruzamento entre colunas temporais, geográficas, demográficas, clínicas e de desfecho dos casos.

Fonte: https://www.gov.br/saude/pt-br/composicao/seidigi/demas

Procedimento de ingestão

Etapa	Procedimento ou parâmetro	Evidência no repositório
1	Download do arquivo compactado (zip) contendo os dados brutos de 2026.	https://github.com/JoaoVictorCarvalho07/api-dados-abertos-saude/blob/master/DENGBR26.csv.zip
2	Leitura com Pandas via Python utilizando separador , ou ; e codificação ISO-8859-1 / UTF-8.	https://github.com/JoaoVictorCarvalho07/api-dados-abertos-saude/blob/master/ra1/ingestao.py
3	Verificação das dimensões (shape), visualização das primeiras linhas e conferencia do número total de registros (~470k).	Imagem a baixo nas observações

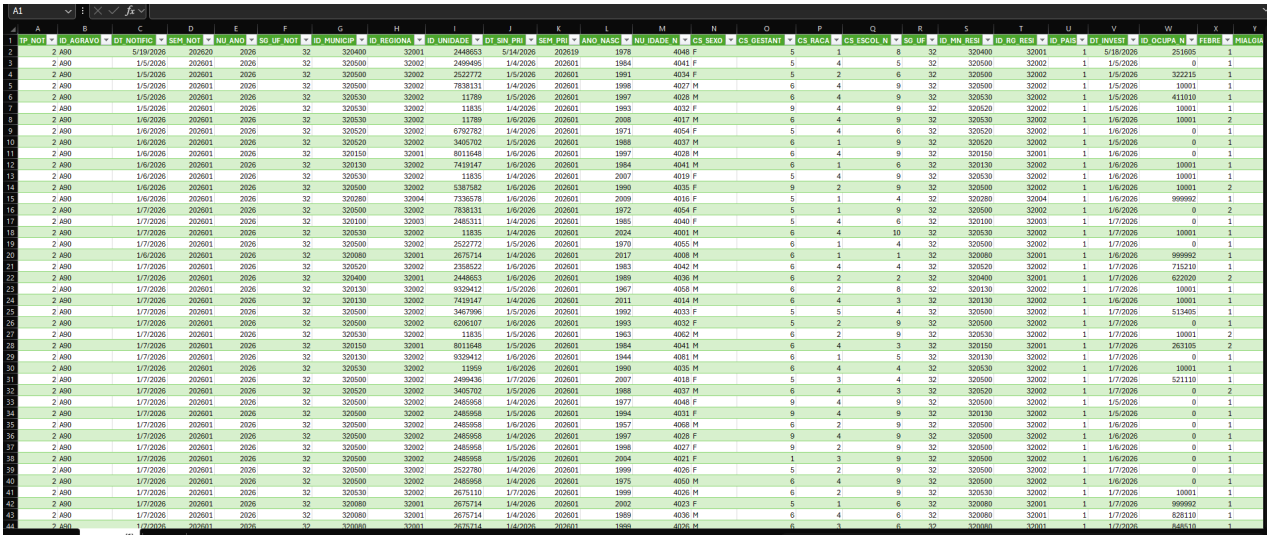
Resultado da ingestão

Volume carregado: 470.000 registros e 120 colunas brutas.

Localização dos dados brutos: Armazenados raiz do projeto com o nome “DENGBR26.csv.zip”

Etapas manuais: Download do arquivo zip no Portal de Dados Abertos e extração do dicionário oficial de dados do SUS em formato PDF/XLS.

Obs: CVS foi convertido para Excel para melhor visualização básica do formato dos dados:



TP_NOT	ID_AGRAVO	DT_NOTIFIC	SEM_NOT	NU_ANO	SG_UF_NOT	ID_MUNICIP	ID_REGIONA	ID_UNIDADE	DT_SIN_PRI	SEM_PRI	ANO_NASC	NU_IDADE_N	CS_SEXO	CS_GESTANT	CS_RACA	CS_ESCOL_N	SG_UF	ID_MN_RESI	ID_RG_RESI	ID_PAIS	DT_INVEST	ID_OCUPA_N	FEBRE	MIALGIA
2	A90	5/19/2026	202620	2026	32	320400	32001	2448653	5/14/2026	202619	1978	4048	F	5	1	8	32	320400	32001	1	5/18/2026	251605	1	
2	A90	1/5/2026	202601	2026	32	320500	32002	2499495	1/4/2026	202601	1984	4041	F	5	4	5	32	320500	32002	1	1/5/2026	0	1	
2	A90	1/5/2026	202601	2026	32	320500	32002	2522772	1/5/2026	202601	1991	4034	F	5	2	6	32	320500	32002	1	1/5/2026	322215	1	
2	A90	1/5/2026	202601	2026	32	320500	32002	7838131	1/4/2026	202601	1998	4027	M	6	4	9	32	320500	32002	1	1/5/2026	10001	1	
2	A90	1/5/2026	202601	2026	32	320530	32002	11789	1/5/2026	202601	1997	4028	M	6	4	9	32	320530	32002	1	1/5/2026	411010	1	
2	A90	1/5/2026	202601	2026	32	320530	32002	11835	1/4/2026	202601	1993	4032	F	9	4	9	32	320520	32002	1	1/5/2026	10001	1	
2	A90	1/6/2026	202601	2026	32	320530	32002	11789	1/6/2026	202601	2008	4017	M	6	4	9	32	320530	32002	1	1/6/2026	10001	2	
2	A90	1/6/2026	202601	2026	32	320520	32002	6792782	1/4/2026	202601	1971	4054	F	5	4	6	32	320520	32002	1	1/6/2026	0	1	
2	A90	1/6/2026	202601	2026	32	320520	32002	3405702	1/5/2026	202601	1988	4037	M	6	1	9	32	320520	32002	1	1/5/2026	0	1	
2	A90	1/6/2026	202601	2026	32	320150	32001	8011648	1/6/2026	202601	1997	4028	M	6	4	9	32	320150	32001	1	1/6/2026	0	1	
2	A90	1/6/2026	202601	2026	32	320130	32002	7419147	1/6/2026	202601	1984	4041	M	6	1	6	32	320130	32002	1	1/6/2026	10001	1	
2	A90	1/6/2026	202601	2026	32	320530	32002	11835	1/4/2026	202601	2007	4019	F	5	4	9	32	320530	32002	1	1/6/2026	10001	1	
2	A90	1/6/2026	202601	2026	32	320500	32002	5387582	1/6/2026	202601	1990	4035	F	9	2	9	32	320500	32002	1	1/6/2026	10001	2	
2	A90	1/6/2026	202601	2026	32	320280	32004	7336578	1/6/2026	202601	2009	4016	F	5	1	4	32	320280	32004	1	1/6/2026	999992	1	
2	A90	1/7/2026	202601	2026	32	320500	32002	7838131	1/6/2026	202601	1972	4054	F	5	1	9	32	320500	32002	1	1/6/2026	0	2	
2	A90	1/7/2026	202601	2026	32	320100	32003	2485311	1/4/2026	202601	1985	4040	F	5	4	6	32	320100	32003	1	1/7/2026	0	1	
2	A90	1/7/2026	202601	2026	32	320530	32002	11835	1/4/2026	202601	2024	4001	M	6	4	10	32	320530	32002	1	1/7/2026	10001	1	
2	A90	1/7/2026	202601	2026	32	320500	32002	2522772	1/5/2026	202601	1970	4055	M	6	1	4	32	320500	32002	1	1/7/2026	0	1	
2	A90	1/6/2026	202601	2026	32	320080	32001	2675714	1/4/2026	202601	2017	4008	M	6	1	1	32	320080	32001	1	1/6/2026	999992	1	
2	A90	1/7/2026	202601	2026	32	320520	32002	2358522	1/6/2026	202601	1983	4042	M	6	4	4	32	320520	32002	1	1/7/2026	715210	1	
2	A90	1/7/2026	202601	2026	32	320400	32001	2448653	1/6/2026	202601	1989	4036	M	6	2	2	32	320400	32001	1	1/7/2026	622020	2	
2	A90	1/7/2026	202601	2026	32	320130	32002	9329412	1/5/2026	202601	1967	4058	M	6	2	8	32	320130	32002	1	1/7/2026	10001	1	
2	A90	1/7/2026	202601	2026	32	320130	32002	7419147	1/4/2026	202601	2011	4014	M	6	4	3	32	320130	32002	1	1/6/2026	10001	1	
2	A90	1/7/2026	202601	2026	32	320500	32002	3467996	1/5/2026	202601	1992	4033	F	5	5	4	32	320500	32002	1	1/7/2026	513405	1	
2	A90	1/7/2026	202601	2026	32	320500	32002	6206107	1/6/2026	202601	1993	4032	F	5	2	9	32	320500	32002	1	1/7/2026	0	1	
2	A90	1/7/2026	202601	2026	32	320530	32002	11835	1/5/2026	202601	1963	4062	M	6	2	9	32	320530	32002	1	1/7/2026	10001	2	
2	A90	1/7/2026	202601	2026	32	320150	32001	8011648	1/5/2026	202601	1984	4041	M	6	4	3	32	320150	32001	1	1/7/2026	263105	2	
2	A90	1/7/2026	202601	2026	32	320130	32002	9329412	1/6/2026	202601	1944	4081	M	6	1	5	32	320130	32002	1	1/7/2026	0	1	
2	A90	1/7/2026	202601	2026	32	320530	32002	11959	1/6/2026	202601	1990	4035	M	6	4	4	32	320530	32002	1	1/7/2026	10001	1	
2	A90	1/7/2026	202601	2026	32	320500	32002	2499436	1/7/2026	202601	2007	4018	F	5	3	4	32	320500	32002	1	1/7/2026	521110	1	
2	A90	1/7/2026	202601	2026	32	320520	32002	3405702	1/5/2026	202601	1988	4037	M	6	4	3	32	320520	32002	1	1/7/2026	0	2	
2	A90	1/7/2026	202601	2026	32	320500	32002	2485958	1/4/2026	202601	1977	4048	F	9	4	9	32	320500	32002	1	1/5/2026	0	1	
2	A90	1/7/2026	202601	2026	32	320500	32002	2485958	1/5/2026	202601	1994	4031	F	9	4	9	32	320130	32002	1	1/5/2026	0	1	
2	A90	1/7/2026	202601	2026	32	320500	32002	2485958	1/6/2026	202601	1957	4068	M	6	2	9	32	320500	32002	1	1/6/2026	0	1	
2	A90	1/7/2026	202601	2026	32	320500	32002	2485958	1/4/2026	202601	1997	4028	F	9	4	9	32	320500	32002	1	1/6/2026	0	1	
2	A90	1/7/2026	202601	2026	32	320500	32002	2485958	1/5/2026	202601	1998	4027	F	9	2	9	32	320500	32002	1	1/6/2026	0	1	
2	A90	1/7/2026	202601	2026	32	320500	32002	2485958	1/5/2026	202601	2004	4021	F	1	3	9	32	320500	32002	1	1/6/2026	0	1	
2	A90	1/7/2026	202601	2026	32	320500	32002	2522780	1/4/2026	202601	1999	4026	F	5	2	9	32	320500	32002	1	1/7/2026	0	1	
2	A90	1/7/2026	202601	2026	32	320500	32002	2485958	1/4/2026	202601	1975	4050	M	6	4	9	32	320500	32002	1	1/6/2026	0	1	
2	A90	1/7/2026	202601	2026	32	320530	32002	2675110	1/7/2026	202601	1999	4026	M	6	2	9	32	320530	32002	1	1/7/2026	10001	1	
2	A90	1/7/2026	202601	2026	32	320080	32001	2675714	1/4/2026	202601	2002	4023	F	5	1	6	32	320080	32001	1	1/7/2026	999992	1	
2	A90	1/7/2026	202601	2026	32	320080	32001	2675714	1/4/2026	202601	1989	4036	M	6	4	6	32	320080	32001	1	1/7/2026	828110	1	
2	A90	1/7/2026	202601	2026	32	320080	32001	2675714	1/4/2026	202601	1999	4026	M	6	3	6	32	320080	32001	1	1/7/2026	848518	1	

RA1 / 03

Compreensão e qualidade

Descreva o que cada registro representa e apresente evidências das verificações de qualidade relevantes para os dados.

Unidade de observação: Cada linha representa uma ficha individual de notificação de caso suspeito ou confirmado de dengue registrada no SINAN.

Identificação dos registros: a base pública não traz o número da notificação nem qualquer identificador do paciente. Não existe, portanto, uma chave que garanta unicidade. Duas linhas idênticas em todas as 121 colunas são tratadas como o mesmo registro repetido; linhas muito parecidas só podem ser apontadas como possíveis duplicatas porém não, podem ser descartadas pois não é possível confirmar que se tratam do mesmo registro.

Dicionário inicial dos dados

Atributo	Significado	Tipo e formato	Unidade ou domínio
DT_NOTIFIC	Data da notificação	AAAA-MM-DD	datas de 2026
DT_SIN_PRI	Data de início dos sintomas	AAAA-MM-DD	não pode ser posterior à notificação
SEM_PRI	Semana epidemiológica dos sintomas	AAAASS	semanas de 2025-2026
SG_UF_NOT / ID_MUNICIP	UF e município de notificação	código IBGE	27 UFs; município com 6 dígitos
SG_UF / ID_MN_RESI	UF e município de residência	código IBGE	27 UFs; município com 6 dígitos
CS_SEXO	Sexo	letra	M, F, I = ignorado
NU_IDADE_N	Idade codificada	4 dígitos	1º dígito = unidade (1 hora, 2 dia, 3 mês, 4 ano); demais = valor
ANO_NASC	Ano de nascimento	AAAA	alternativa para a idade
CLASSI_FIN	Classificação final	código	5, 8, 10, 11, 12, 13; vazio = em investigação
CRITERIO	Critério de confirmação	código	1 laboratorial, 2 clínico-epidemiológico, 3 em investigação
HOSPITALIZ	Houve hospitalização	código	1 sim, 2 não, 9 ignorado

Atributo	Significado	Tipo e formato	Unidade ou domínio
EVOLUCAO	Evolução do caso	código	1 cura, 2 óbito pelo agravo, 3 outras causas, 4 em investigação, 9 ignorado
DIABETES / HIPERTENSA	Comorbidades	código	1 sim, 2 não, 9 ignorado

Diagnóstico de qualidade

Considere ausências, duplicidades, tipos, formatos, valores inválidos, categorias e possíveis outliers. Registre também verificações sem problemas; use "não se aplica" com justificativa quando necessário.

ID	Verificação e regra	Resultado observado	Evidência
Q1	Colunas 100% vazias	0 colunas	*ra1_dengue_2026.ipybn :Seção 3.2*
Q2	Colunas com um único valor (TP_NOT, ID_AGRAVO, NU_ANO)	3 colunas	*ra1_dengue_2026.ipybn :Seção 3.2*
Q3	Duplicatas exatas	230 registros	*ra1_dengue_2026.ipybn :Seção 3.4*
Q4	Possíveis duplicatas (mesma chave, linha diferente)	2,925 registros	*ra1_dengue_2026.ipybn :Seção 3.4*
Q5	Datas fora do formato AAAA-MM-DD	0 valores	*ra1_dengue_2026.ipybn :Seção 3.5*
Q6	Registros com alguma data fora do período válido de 2026	137 registros	*ra1_dengue_2026.ipybn :Seção 3.5*
Q7	Início dos sintomas depois da notificação	0 registros	*ra1_dengue_2026.ipybn :Seção 3.5*
Q8	Data de digitação antes da notificação	7 registros	*ra1_dengue_2026.ipybn :Seção 3.5*
Q9	Encerramento antes da notificação	55 registros	*ra1_dengue_2026.ipybn :Seção 3.5*
Q10	Atraso extremo de sintomas → notificação no intervalo acima de 60 dias	2,442 registros	*ra1_dengue_2026.ipybn :Seção 3.8*
Q11	CLASSI_FIN fora do domínio (código '0')	4,318 registros	*ra1_dengue_2026.ipybn :Seção 3.8*
Q12	CLASSI_FIN vazio (caso em investigação)	30,577 registros	*ra1_dengue_2026.ipybn :Seção 3.6*
Q13	Idade vazia ou com unidade inválida	3 registros	*ra1_dengue_2026.ipybn :Seção 3.7*
Q14	Idade acima de 120 anos	15 registros	*ra1_dengue_2026.ipybn :Seção 3.7*

ID	Verificação e regra	Resultado observado	Evidência
Q15	Idade diverge do ano de nascimento	1 registros	*ra1_dengue_2026.ipybn :Seção 3.7*
Q16	Sexo ignorado ou fora de M/F	279 registros	*ra1_dengue_2026.ipybn :Seção 3.6*
Q17	Diabetes sem sim/não (vazio ou 9)	14,941 registros	*ra1_dengue_2026.ipybn :Seção 3.3*
Q18	Hipertensão sem sim/não (vazio ou 9)	14,942 registros	*ra1_dengue_2026.ipybn :Seção 3.3*
Q19	Hospitalizado sem data de internação	2,419 registros	*ra1_dengue_2026.ipybn :Seção 3.6*
Q20	UF de residência vazia ou inexistente	0 registros	*ra1_dengue_2026.ipybn :Seção 3.6*

Impacto dos problemas identificados

A base tem 470.451 notificações × 121 colunas, de 04/01 a 04/10/2026, todas lidas como texto. As principais características observadas:

- **Estrutura:** nenhuma coluna está totalmente vazia, mas 56 das 121 têm mais de 90% de ausência. São campos preenchidos só em situações específicas (exames, sinais de alarme, gravidade, chikungunya), então a ausência ali é esperada. Três colunas são constantes (TP_NOT, ID_AGRAVO, NU_ANO).
- **Colunas das perguntas:** datas, UF, município, sexo e idade estão completos. As ausências relevantes estão em EVOLUCAO (24,4%), HOSPITALIZ (24,2%), CRITERIO (19,1%), CLASSI_FIN (6,5%) e nas comorbidades (3,2%).
- **Duplicidade:** 230 linhas são cópias exatas (0,05%). Outras 2.925 (0,62%) compartilham unidade, datas, idade, sexo e residência, mas não podem ser confirmadas como a mesma pessoa, porque a base não tem identificador de paciente.
- **Datas:** todas no formato AAAA-MM-DD e, nas colunas das perguntas, dentro do período; nenhum caso tem sintomas depois da notificação. Os problemas ficam em colunas secundárias: 137 registros têm datas impossíveis (exame NS1 em 1920, sinais de alarme em 2036, gravidade em 2062), 7 foram digitados antes da notificação e 55 foram encerrados antes dela.
- **Códigos fora do dicionário:** CLASSI_FIN = 0 aparece em 4.318 registros, todos do Espírito Santo (21,2% das notificações do estado), que grava o vazio como 0. O mesmo 0 aparece em EVOLUCAO (5.518) e CRITERIO (4.347). Além disso, 30.577 casos (6,5%) ainda não têm classificação final.
- **Sem casos descartados:** o código 5 ("descartado") não aparece nenhuma vez. O arquivo público traz apenas casos prováveis (confirmados, inconclusivos e em investigação), então as perguntas medem proporções entre casos prováveis e não é possível calcular taxa de confirmação.
- **Idade:** NU_IDADE_N mistura unidade e valor. 98,6% das idades estão em anos, mas há registros em meses, dias e horas; 15 idades passam de 120 anos (a maior chega a 407) e 3 são inválidas.
- **Outliers:** o atraso entre sintomas e notificação tem mediana de 3 dias e percentil 99 de 38 dias, com 2.442 notificações (0,52%) acima de 60 dias e máximo de 238.

RA1 / 04

Limpeza e preparação

Relacione cada intervenção ao diagnóstico. Justifique tanto os tratamentos realizados quanto as decisões de manter os dados.

Registro das decisões

Decisão D1 (Relacionada a Q3): Remoção de duplicatas exatas

- **Problema:** Linhas idênticas em todas as 121 colunas do arquivo oficial.
- **Tratamento e justificativa:** Remoção das cópias exatas para evitar inflacionar a contagem de casos na pergunta P1.
- **Implementação:** Utilização de drop_duplicates() e criação da coluna de rastreabilidade id_registro.
- **Validação:** Verificação de que não restaram duplicatas exatas remanescentes.

Decisão D2 (Relacionada a Q4): Tratamento de possíveis duplicatas

- **Problema:** Registros compartilhando a mesma chave analítica, mas com conteúdos divergentes.
- **Tratamento e justificativa:** Como a base não possui identificador de paciente, a exclusão apagaria pessoas diferentes; portanto, as linhas foram mantidas e sinalizadas em uma coluna específica.
- **Implementação:** Criação da coluna binária possivel_duplicata com base na chave analítica.
- **Validação:** Confirmação de que nenhuma linha foi removida indevidamente

---

Decisão D3 (Relacionada a Q1, Q2, Q8, Q9, Q19): Seleção de atributos relevantes

- **Problema:** Presença de 121 colunas brutas, sendo a maioria não utilizada para responder às perguntas analíticas.
- **Tratamento e justificativa:** Filtragem mantendo apenas as 16 colunas estritamente necessárias para as perguntas P1 a P3.
- **Implementação:** Restrição do DataFrame às colunas analíticas e de suporte essenciais.
- **Validação:** Redução do escopo para 18 colunas finais no fluxo de limpeza.

Decisão D4 (Relacionada a Q5, Q6, Q7): Conversão e validação de datas

Problema: Datas armazenadas como texto simples (string) e potenciais anomalias temporais.

Tratamento e justificativa: Conversão para o tipo data (datetime64). Datas de sintomas impossíveis ou futuras foram transformadas em valores vazios e sinalizadas.

Implementação: Uso de pd.to_datetime com restrição ao período válido do projeto.

Validação: Certificação de que todas as datas mantidas estão no formato correto e dentro do período.

Decisão D5 (Relacionada a Q11, Q12): Tratamento da Classificação Final (CLASSI_FIN)

- **Problema:** Presença do código inválido 0 (utilizado exclusivamente pelo Espírito Santo para representar vazios) e de casos em investigação com valores nulos.
- **Tratamento e justificativa:** Agrupamento do código 0 e dos valores vazios sob o rótulo unificado **"Sem classificação"**, isolando-os para que fiquem fora do denominador de gravidade.
- **Implementação:** Mapeamento condicional para os rótulos oficiais do dicionário do SINAN.
- **Validação:** Confirmação de que os códigos inválidos foram completamente reclassificados.

Decisão D6 (Relacionada a Q13, Q14, Q15): Padronização e tratamento da Idade

- **Problema:** O campo NU_IDADE_N mistura unidade de medida e valor numérico, contendo registros inválidos ou com idades biologicamente impossíveis acima de 120 anos.
- **Tratamento e justificativa:** Conversão matemática para anos completos utilizando a unidade codificada; idades superiores a 120 anos foram zeradas/tornadas vazias, recorrendo-se ao ano de nascimento (ANO_NASC) como alternativa de recuperação.
- **Implementação:** Extração do primeiro dígito multiplicador e restrição estrita ao intervalo de 0 a 120 anos.
- **Validação:** Verificação de que o intervalo final de idade está correto.

Decisão D7 (Relacionada a Q16): Tratamento do Sexo (CS_SEXO)

- **Problema:** Presença de registros preenchidos com o código I (ignorado).
- **Tratamento e justificativa:** Conversão do sexo ignorado para valor vazio, mantendo a linha intacta para análises que não dependam desse campo.
- **Implementação:** Mapeamento de M para Masculino, F para Feminino e I para nulo.
- **Validação:** Confirmação de que as contagens de Masculino e Feminino permaneceram inalteradas.

Decisão D8 (Relacionada a Q17, Q18): Tratamento de comorbidades e hospitalização

- **Problema:** Campos de comorbidades (diabetes, hipertensão) e hospitalização contendo códigos de ignorado (9) ou valores vazios.
- **Tratamento e justificativa:** Conversão dos códigos de resposta para tipos booleanos (True/False) e os valores de ignorado/vazio para nulos, preservando a integridade das linhas.
- **Implementação:** Mapeamento booleano condicional para cada variável de condição de saúde.
- **Validação:** Verificação de que os registros nulos foram isolados corretamente.

Decisão D9 (Relacionada a Q20): Tradução de códigos geográficos

- **Problema:** As UFs e municípios encontravam-se apenas em formato de códigos numéricos do IBGE.
- **Tratamento e justificativa:** Tradução dos códigos das Unidades da Federação para suas respectivas siglas textuais e regiões geográficas, facilitando a legibilidade analítica.
- **Implementação:** Cruzamento com dicionário de códigos UF e extração do primeiro dígito para definir a macro-região.
- **Validação:** Confirmação de que todas as 27 UFs foram traduzidas sem perdas.

Decisão D10 (Relacionada a Q10): Manutenção de atrasos extremos

- **Problema:** Presença de notificações com intervalo superior a 60 dias entre a data de início dos sintomas e o registro da notificação.
- **Tratamento e justificativa:** Os registros foram mantidos na base, pois a notificação tardia é um fenômeno epidemiológico real e plausível (um valor extremo isolado não justifica exclusão).
- **Implementação:** Cálculo do atraso em dias mantendo o registro integralmente.
- **Validação:** Certificação de que o indicador de atraso foi gerado sem apagar linhas.

Resumo das intervenções

Decisão	Ação executada	Impacto nos dados	Evidência
D1	Remoção de duplicatas exatas	-230 registros	Seção 4.2 (D1)
D2	Sinalização e manutenção de possíveis duplicatas	5.797 linhas sinalizadas (2.925 grupos)	Seção 4.2 (D2)
D3	Seleção de colunas essenciais para as perguntas	Redução de 121 para 18 colunas brutas mantidas	Seção 4.2 (D3)
D4	Conversão e validação de datas	0 datas inválidas de sintomas após filtro	Seção 4.2 (D4)
D5	Tratamento e agrupamento da Classificação Final (CLASSI_FIN)	34.829 registros reclassificados ("Sem classificação")	Seção 4.2 (D5)
D6	Conversão e padronização da Idade em anos	3 idades vazias corrigidas/recuperadas via nascimento	Seção 4.2 (D6)
D7	Tratamento do sexo ignorado (I)	279 registros com sexo tornado vazio	Seção 4.2 (D7)
D8	Conversão de comorbidades e internação para booleanos	14.899 a 14.900 vazios isolados em comorbidades	Seção 4.2 (D8)
D9	Tradução de códigos geográficos (UFs e Regiões)	27 UFs e regiões devidamente mapeadas	Seção 4.2 (D9)
D10	Manutenção de notificações com atraso extremo	2.442 registros mantidos (atraso > 60 dias)	Seção 4.2 (D10)

RA1 / 05

Conjunto de dados resultante

Identifique a saída do RA1 e demonstre sua consistência para uso nas próximas etapas.

Arquivo ou conjunto final: dengue_brasil_2026.parquet

Caminho no repositório: dados/preparados/dengue_brasil_2026.parquet

Unidade de observação final: Cada linha representa uma notificação de dengue mantida após a remoção de duplicatas exatas. O conjunto contém notificações de casos classificados ou ainda sem classificação final, não exclusivamente casos confirmados ou prováveis.

Dicionário atualizado: Seção 6.4 do notebook ra1_dengue_2026.ipynb, que apresenta os 24 atributos do conjunto preparado, suas origens, descrições, tipos e percentuais de valores ausentes

Comparação antes e depois

Medida	Após ingestão	Após preparação	Explicação da diferença
Registros	470.451	470.221	Remoção de 230 duplicatas exatas
Atributos	121	24	Seleção de atributos, padronização e criação de variáveis derivadas
Duplicatas exatas	230	0	As cópias exatas foram removidas
Datas armazenadas como texto	9 colunas de data	0	Conversão das datas mantidas para tipo data
CLASSI_FIN fora do domínio	4.318	0	Códigos inválidos agrupados em “Sem classificação”
Idades ausentes ou inutilizáveis	18 antes da recuperação	15	Três idades recuperadas pelo ano de nascimento
Sexo sem informação válida	279	279	Registros mantidos, com sexo ausente
Diabetes sem resposta válida	14.941	14.941	Registros mantidos, com valor ausente
Hipertensão sem resposta válida	14.942	14.942	Registros mantidos, com valor ausente
Atrasos de notificação superiores a 60 dias	2.442	2.442	Registros mantidos por serem atrasos plausíveis
Linhas sinalizadas como possíveis duplicatas	5.797	5.797	Registros mantidos e sinalizados para análises posteriores

Verificações finais

O resultado principal é que a base passou de 470.451 registros e 121 colunas para 470.221 registros e 24 colunas. A redução de linhas decorre exclusivamente da remoção das 230 cópias exatas. As possíveis duplicatas não foram excluídas.

Foram executadas verificações de consistência no conjunto preparado, com os seguintes resultados:

- **Integridade dos registros:** o conjunto final contém 470.221 linhas, correspondentes à base original após a remoção de 230 duplicatas exatas.
- **Identificação:** a coluna id_registro mantém a rastreabilidade até a posição do registro no arquivo original e apresenta valores únicos.
- **Datas:** as datas de notificação estão dentro do período definido; as datas de sintomas estão dentro do período válido ou são mantidas como ausentes quando inválidas. Não foram identificados sintomas posteriores à notificação nem atrasos negativos.
- **Idade:** os valores foram padronizados para anos completos, com idades entre 0 e 120 anos ou valores ausentes. Três idades inválidas foram recuperadas pelo ano de nascimento, e 15 permaneceram ausentes.
- **Domínios categóricos:** a classificação final foi convertida para rótulos padronizados, incluindo a categoria “Sem classificação”. O sexo foi padronizado para Masculino e Feminino, mantendo valores ausentes quando ignorado.
- **Comorbidades e hospitalização:** as respostas foram convertidas para valores booleanos, preservando como ausentes os registros sem informação válida.
- **Localização:** os códigos geográficos foram traduzidos para siglas das UFs e regiões. Nenhuma UF de residência ou de notificação ficou sem tradução.
- **Variáveis derivadas:** foram criados o mês dos sintomas, as faixas etárias, o indicador de caso grave e o atraso entre sintomas e notificação.
- **Validação da saída:** todas as regras programadas na seção 6.1 do notebook foram aprovadas. Após a gravação do arquivo Parquet, a releitura apresentou as mesmas dimensões e os mesmos tipos de dados do conjunto preparado.

Evidências: notebook ra1_dengue_2026.ipynb, seções 4.2, 5, 6.1, 6.2, 6.3 e 6.4.

Limitações e pendências

O conjunto preparado apresenta algumas limitações que devem ser consideradas nas próximas etapas:

- **Período incompleto:** os dados utilizados vão até 10/10/2026. O ano epidemiológico ainda não terminou, e as notificações mais recentes podem sofrer atualizações.
- **Ausência de identificador individual:** não é possível confirmar se registros semelhantes pertencem à mesma pessoa. Por isso, as possíveis duplicatas foram mantidas e sinalizadas.
- **Dados ausentes:** permanecem valores sem informação em idade, sexo, classificação final, evolução, hospitalização e comorbidades. Essas ausências podem reduzir a quantidade de registros disponíveis para cada análise.
- **Classificação dos casos:** 34.829 registros foram agrupados como “Sem classificação”, incluindo valores vazios e o código 0. Esses registros não devem integrar o denominador da análise de gravidade.
- **Representatividade epidemiológica:** o volume de notificações por estado não representa, isoladamente, a incidência da doença. Comparações por habitante exigirão dados populacionais complementares.
- **Variáveis de desfecho:** a ausência de informações sobre hospitalização e evolução limita análises relacionadas à evolução clínica dos pacientes.
- **Qualidade da fonte:** os resultados dependem do preenchimento das notificações e das atualizações disponibilizadas pelo SINAN/Ministério da Saúde.

Essas limitações devem ser consideradas na interpretação dos resultados dos próximos RAs. O conjunto preparado foi estruturado para permitir análises posteriores, sem eliminar registros apenas por apresentarem informações incompletas ou possíveis duplicidades.

RA1 / 06

Organização e reprodutibilidade

Explique como outra pessoa pode obter os dados e executar o fluxo completo do RA1.

Repositório e versão https://github.com/JoaoVictorCarvalho07/api-dados-abertos-saude/tree/master/ra1

Ultimo commit:
https://github.com/JoaoVictorCarvalho07/api-dados-abertos-saude/commit/73c967f613fa9542dfe1d93a10f89a7671b37433 ah

Ambiente Python 3.11.9 (Windows) • pandas 2.2.3, pyarrow 18.1.0, matplotlib 3.9.2, jupyter 1.1.1, ipykernel 6.29.5, nbconvert 7.16.4 • dependências fixadas em requirements.txt

Localização dos artefatos

Artefato	Caminho ou forma de obtenção
Dados brutos	DENGBR26.csv.zip, obtido automaticamente pela URL oficial configurada no notebook.
Código de ingestão e preparação	ra1/ra1_dengue_2026.ipynb, conforme a estrutura indicada no repositório; confirmar o caminho exato na branch da entrega.
Dados preparados	dados/preparados/dengue_brasil_2026.parquet, gerado pelo notebook.
Documentação e dependências	README: https://github.com/JoaoVictorCarvalho07/api-dados-abertos-saude/blob/master/ra1/RESUMO.md Dependências: https://github.com/JoaoVictorCarvalho07/api-dados-abertos-saude/blob/master/requirements.txt

Passos para reprodução

Ordem	Instrução executável	Resultado esperado
1	Clonar o repositório e preparar um ambiente Python com as bibliotecas necessárias.	Ambiente configurado, com pandas, NumPy, Matplotlib, IPython e PyArrow disponíveis.
2	Abrir o notebook ra1_dengue_2026.ipynb no Jupyter e conferir o diretório de trabalho.	A raiz do projeto é identificada corretamente pelos caminhos definidos no código.
3	Executar todas as células do notebook, na ordem apresentada, com acesso à internet para obter o arquivo bruto caso ele não esteja disponível localmente.	A base é carregada, as verificações de qualidade são realizadas e as etapas de limpeza e transformação são executadas.

Ordem	Instrução executável	Resultado esperado
4	Verificar a saída em dados/preparados/dengue_brasil_2026.parquet.	Arquivo Parquet gerado com 470.221 linhas e 24 colunas, de acordo com a execução registrada.
5	Conferir as validações da seção 6.1 e a releitura do Parquet na seção 6.2.	Todas as regras de validação são aprovadas e os tipos e dimensões são preservados na releitura.

Verificação da reprodução

Data de referência dos resultados: 21/10/2026.

Responsável: João Victor Carvalho de Freitas e Matheus Henrique Heinzen

Ambiente: Python e Jupyter Notebook, com as versões das bibliotecas registradas no ambiente de execução.

Resultado esperado: execução completa do notebook sem falhas nas regras de validação, geração do arquivo dados/preparados/dengue_brasil_2026.parquet e confirmação de 470.221 linhas × 24 colunas.

Evidência: saídas registradas nas seções 4.2, 6.1, 6.2 e 6.3 do notebook.

Quando houver restrições de acesso aos dados, explique como um avaliador autorizado poderá reproduzir a execução. Documente configurações necessárias sem expor credenciais.

RA1 / 07

Referências e anexos

BRASIL. Ministério da Saúde. Secretaria de Informação e Saúde Digital (SEIDIGI). Departamento de Monitoramento, Avaliação e Disseminação de Informações Estratégicas em Saúde (DEMAS). Disponível em: https://www.gov.br/saude/pt-br/composicao/seidigi/demas. Acesso em: out. 2026.

BRASIL. Ministério da Saúde. Portal de Dados Abertos do SUS: Arboviroses - Dengue. Disponível em: https://dadosabertos.saude.gov.br/dataset/arboviroses-dengue. Acesso em: out. 2026.

Anexos opcionais

Identificação	Conteúdo	Localização
Dicionário de Dados - Dengue	Dicionário disponibilizado pelo Portal de Dados Abertos do SUS, contendo as informações dos Nomes dos Campos, também o tipo, categoria, descrição e características dos dados.	https://dadosabertos.saude.gov.br/dataset/arboviroses-dengue/resource/ccc60f03-2834-49a3-98f7-7ee76f50a316